

Resmî veriyle geliştirilmiş kamu analitiği prototipi

Ertesi gün hangi binalarda heating veya hot water şikayeti bekleniyor?

Bu çalışma, NYC'de resmi 311, HPD, NOAA ve Census CRE verilerini birleştirerek ertesi gün complaint riski yüksek binaları tahmin eder ve denetim önceliği üretir.

Gerçek resmi veri

Operasyonel çıktı

Yorumlanabilir model

Neden önemli?

- 1 Isınma ve sıcak su temel yaşam hizmetidir.
- 2 Denetim kapasitesi sınırlıdır; her binaya aynı anda gidilemez.
- 3 Amaç, şikayet geldikten sonra değil bir gün önce risk sinyali üretebilmektir.

Bu nedenle proje yalnızca geçmiş göstermiyor; ertesi gün için öncelik üretmeye çalışıyor.

Heat-season final build'in büyüklüğü

282,296

complaint kaydı

36,170

benzersiz bina

8,789,310

building-day satırı

Oct'24-May'25

Neyi üretir?

Üretir

- Ertesi gün risk skoru üretir
- Günlük inspection priority list çıkarır
- Equity-aware yorumlanabilir çıktı verir

Tasarım sınırı

- Summer heatwave modeli değildir
- Sentetik veri kullanmaz
- Karar destek aracıdır; otomatik denetim sistemi değildir

Resmi kaynaklar

NYC 311

HPD complaints

HPD buildings

HPD registrations

HPD violations

Heat Sensor Program


NOAA weather

Census CRE

Heat-season aylık profil

Pozitif bina sayısı kış aylarında yükseliyor; en yoğun dönem en soğuk pencereyle çıkıyor.

Monthly positive buildings



Oct 7,654 | Nov 11,561 | Dec 15,835 | Jan 16,581
Feb 11,039 | Mar 7,615 | Apr 5,586 | May 3,196

Sonuçları nasıl okumalıyım?

0.453

Mean P@10

0.274

Mean P@50

47.3x

Lift@50

p<1e-4

ANOVA

Base rate düşük olduğu için F1 tek başına yeterli değil. Esas soru, modelin günlük top listedeki doğru bina yoğunluğunu yükseltip yükseltmediği.

Bu proje tam olarak nasıl çalışıyor?

Amaç bir dashboard göstermek değil; ertesi gün için denetim önceliği üreten, kanıtlanabilir bir building-day karar destek akışı kurmak.

Karar sorusu

Yarın sınırlı denetim kapasitesiyle önce hangi binalara gidilmeli?

0/1

hedef

8.79M

panel

Top-50

çıktı

Analitik akış

Her kutu sınıfta gösterebileceğin somut bir işlem: veri çekme, join, model, test ve operasyonel çıktı.

1

Resmî veri

311 complaint + HPD bina/violation + NOAA hava + Census CRE.

2

Leakage-safe panel

Her satır bir bina-gün. Sadece o güne kadar bilinen bilgi kullanıldı.

3

Ana model

Logistic regression $P(Y=1)$ üretir; skorlar günlük risk sırasına çevrilir.

4

İstatistik kontrol

ANOVA, NB, GEE/GLMM, CI, drift ve OOT validation ayrı ayrı raporlandı.

5

Karar çıktısı

Top-50 priority list, why_risky açıklaması, API ve dashboard çıktısı.

Çalıştığını nasıl kanıtlıyorum?

1. Veri kanıtı

282,296 complaint,
36,170 bina, 8.79M
building-day panel.

2. Model kanıtı

$P@50=0.274$ ve
 $Lift@50=47.3x$.

3. Dayanıklılık

OOT Mean $P@50=0.689$;
CI ve drift raporu üretildi.

4. Demo

FastAPI, Docker,
dashboard, QR broşür
ve AWS kanıt raporları
pakette.

Hocaya kısa cevap: Model şehir adına karar vermez; denetçinin ilk bakacağı binaları veriyle sıralar.

Hangi yöntemi neden kullandım?

Tek modelle her şeyi çözmüş gibi davranmadım. Her yöntem farklı bir istatistik sorusuna cevap verdi; ana karar modeli calibrated logistic ranking olarak kaldı.

1. LOJİSTİK REGRESYON | ANA MODEL

Ertesi gün şikayet olur mu?

$$\text{logit}(p) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

Neden kullandım?

Hedef 0/1 olduğu için olasılık üretir. Bu olasılık doğrudan risk skoru ve denetim sırası olarak kullanıldı.

$$P@50=0.274 \mid \text{Lift}@50=47.3x \mid \text{AUC}=0.804$$

2. ANOVA | HİPOTEZ TESTİ

Aylar arasında ortalama fark var mı?

$$H_0: \mu_{\text{Oct}} = \dots = \mu_{\text{May}} \mid F = \text{MSB} / \text{MSW}$$

Neden kullandım?

Modelden önce veri hikayesini test eder. Kış aylarında complaint yoğunluğu gerçekten farklı mı sorusuna cevap verir.

$$F=33.62 \mid p<0.0001 \mid \eta^2=0.500$$

3. NEGATIVE BINOMIAL | COUNT MODEL

Şikayet sayısı hangi faktörlerle artıyor?

$$Y_{\text{count}} \sim \text{NB}(\mu, \theta), \log(\mu) = \beta X$$

Neden kullandım?

Sadece olur/olmaz değil, kaç şikayet geldiğini de açıklar. Count veride varyans yüksek olduğu için Poisson'dan daha uygundur.

$$\text{RMSE}=0.548 \mid \text{MAE}=0.070 \mid \text{current count } 4.16x$$

4. GEE / GLMM + BACKTEST | KONTROL

Aynı binanın tekrar eden günleri sonucu bozuyor mu?

$$\text{GLMM: } \text{logit}(\text{pit}) = \beta X_{it} + u_i$$

Neden kullandım?

Panel veri bağımsız değildir; aynı bina birçok gün tekrar eder. GEE/GLMM diagnostic, OOT ve rolling backtest bu riski kontrol eder.

$$\text{OOT } P@50=0.689 \mid \text{primary model} = \text{logistic ranking}$$

Lisans seviyesinde en net ayırım

Logistic

olasılık ve sıralama
hangi bina riskli?

ANOVA

grup ortalaması testi
aylar gerçekten farklı mı?

NB

sayım modeli
kaç complaint beklenir?

GEE/GLMM

panel diagnostic
tekrar bina etkisi var mı?

Tahtada yazılacak hipotez ve formüller

Bu sayfa, hocanın 'regresyonu, ANOVA'yı ve NB'yi ne için kullandın?' sorusuna matematik tarafı fazla ağırlaşmadan cevap verir.

Model birimi

i,t
bina-gün

Y=1
şikayet var

X
features

Örnek özellikler: geçmiş complaint, açık violation, hava/sıcaklık yükü, building attributes, CRE vulnerability.

1. Logistic regression

$$\text{logit}(p) = \ln(p/(1-p)) = \beta X$$

$$p = 1/(1 + e^{-\eta})$$

Yorum: p, ertesi gün complaint olasılığıdır. Büyük p değeri daha yukarı priority rank demektir. Bu projede $P@50=0.274$.

2. ANOVA

$$H_0: \mu_{\text{Oct}} = \mu_{\text{Nov}} = \dots = \mu_{\text{May}}$$

$$F = MS_{\text{between}} / MS_{\text{within}}$$

Yorum: H_0 reddedildiğinde ay ortalamaları aynı değildir. Bu projede $F=33.62$, $p<0.0001$ ve $\eta^2=0.500$.

3. Negative Binomial

$$Y_{\text{count}} \sim \text{NB}(\mu, \theta)$$

$$\text{Var}(Y) > E(Y) \text{ ise uygundur}$$

Yorum: Complaint sayısı gibi count hedeflerde aşırı değişkenlik olabilir. NB bu oynaklığı Poisson'a göre daha esnek yakalar. $\text{RMSE}=0.548$.

4. Panel kontrolü

$$\text{GEE: cluster=building_id}$$

$$\text{GLMM: logit}(\text{pit}) = \beta X_{it} + u_i$$

Yorum: Aynı bina tekrar tekrar gözlemlendiği için bağımsızlık varsayımı zayıflar. Bu modeller ana karar değil, diagnostic kontroldür. OOT $P@50=0.689$.

Hocaya 20 saniyelik cevap

Ana karar modeli logistic regression; çünkü hedef 0/1. ANOVA'yı mevsimsel ortalama farkı var mı diye kullandım. Negative Binomial, şikayet sayısı gibi count hedefi anlamak için destek model. GEE/GLMM ise aynı binanın tekrar eden kayıtları sonuçları bozuyor mu diye diagnostic kontrol.

Alt çizgi: GLMM ana model değil; ana model calibrated logistic ranking.

Projeyi dinleyen kişi ne anlamalı?

Sonuç, 'çok veri kullandım' demek değil; düşük base-rate ortamında daha iyi öncelik sırası üretip bunu açık ve dürüst biçimde raporlamak.

Akılda kalacak 6 kanıt

282,296

complaint

36,170

bina

8.79M

building-day

0.274

Mean P@50

47.3x

Lift@50

0.689

OOT P@50

Örnek priority çıktısı

1

BRONX

530 EAST 169 STREET

prior 645

2

MANHATTAN

76 ST NICHOLAS PLACE

prior 592

3

BRONX

957 WOODYCREST AVENUE

prior 479

4

MANHATTAN

2 CHARLTON STREET

prior 413

Bu liste otomatik karar değildir; denetçinin nereye önce bakacağını önerir.

Sık gelecek 4 soru

Neye çare?

Denetim kapasitesi sınırlıyken ertesi gün öncelik sırası üretir.

Neden F1 tek başına değil?

Positive rate düşük; bu yüzden ranking, Lift@K ve P@K daha operasyonel.

Equity nerede?

CRE vulnerability panele eklendi; priority list equity skoru ile de okunur.

Sınır ne?

Heating-season karar desteği; yaz heatwave modeli veya otomatik ceza sistemi değil.

Güven zinciri

Resmî veri

NYC 311, HPD, NOAA,
Census CRE

Leakage audit

Gelecek bilgi modele
sokulmadı

Validation

CI, drift, OOT ve
backtest raporlandı

Demo proof

FastAPI/Docker/QR/AW
S kanıtları pakette

Tek cümle: Resmî veriden açıklanabilir günlük denetim önceliği üreten istatistik + veri bilimi prototipi.